Reporte de Resultados: Optimización Financiera de Vuelos

Preparado por: Valentina Muñoz Palma y Kevin Leonardo Chaparro Reyes

Dirigido a: Departamento de finanzas / dirección de seguimiento para perdidas por retrasos

Fecha: 16 de abril de 2026

1. Contexto y Objetivos del Proyecto

El presente proyecto consistió en el desarrollo de un modelo predictivo para identificar retrasos críticos (superiores a 15 minutos) en la red de vuelos de EE. UU. (2015).

- **Objetivo Financiero:** Proteger la liquidez de la compañía ante el impacto económico de las compensaciones, estimadas en **$150 USD** por pasajero afectado.
- **Variables Clave:** El análisis se centró en la hora de despegue (**DEP_HOUR**), la aerolínea (**AIRLINE**) y el aeropuerto de origen (**ORIGIN**). Estas variables permiten al departamento financiero identificar con precisión dónde se generan las mayores fugas de capital y dirigir recursos preventivos para mitigar gastos.

2. Diagnóstico: Análisis Exploratorio de Datos (EDA)

Antes del modelado, se procesaron **5,332,914 de registros** mediante PySpark para identificar los focos de fuga de capital.

Resumen General de Operaciones

- **Total de vuelos:** 5,332,914
- **Vuelos puntuales:** 4,335,703
- **Vuelos retrasados:** 997,211 (Tasa global: **18.70%**)

Hallazgos de Riesgo por Categoría

- **Temporalidad (DEP_HOUR):** Aunque la hora es un predictor fuerte, el gasto se distribuye de manera atomizada ("goteo"). El pico máximo ocurre a las 5:00 PM (Hora 17) con un 8.95% del gasto total, lo que hace difícil pausar operaciones en horarios específicos.

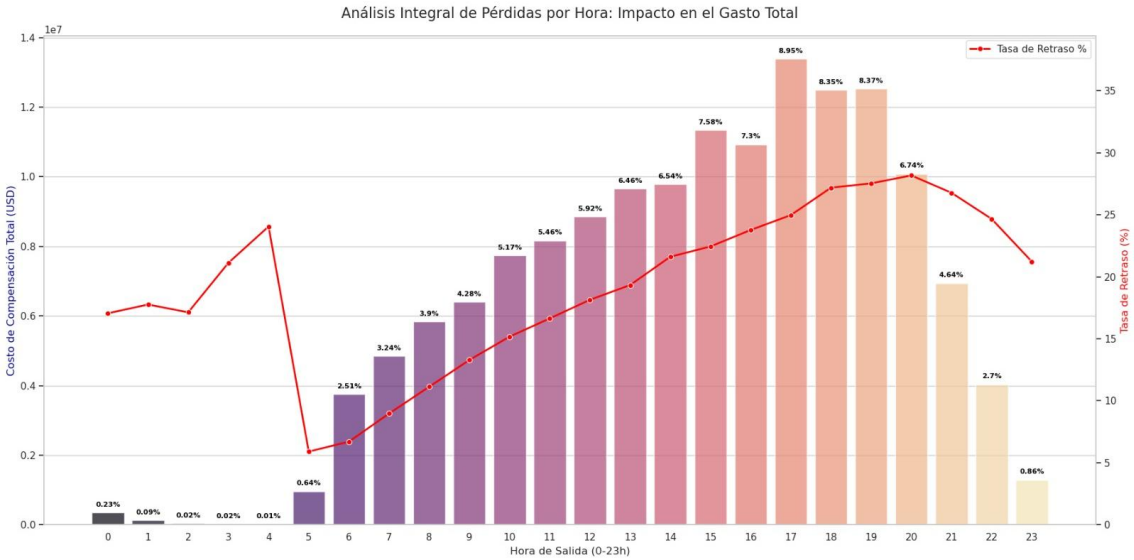

- **Concentración por Aerolínea:** * **Southwest (WN):** Punto crítico que representa el **25.17%** del gasto total de la red.
    - **Delta (DL) y American (AA):** Pese a tasas de retraso bajas (~15-17%), su alto volumen las hace responsables del **11%** del gasto.
    - **Spirit (NK):** Alta tasa de retraso (27.74%) pero bajo impacto financiero (2.98%) por tamaño de flota.

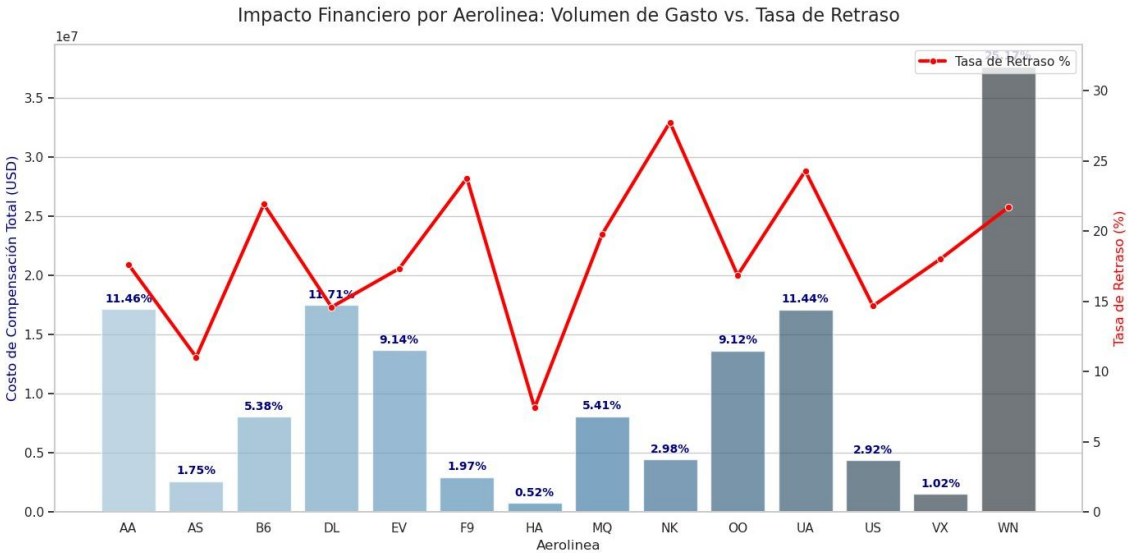

- **Estacionalidad Mensual:** Junio y julio concentran el **22%** del gasto anual, mientras que noviembre es el mes más eficiente (14.91% de retrasos).

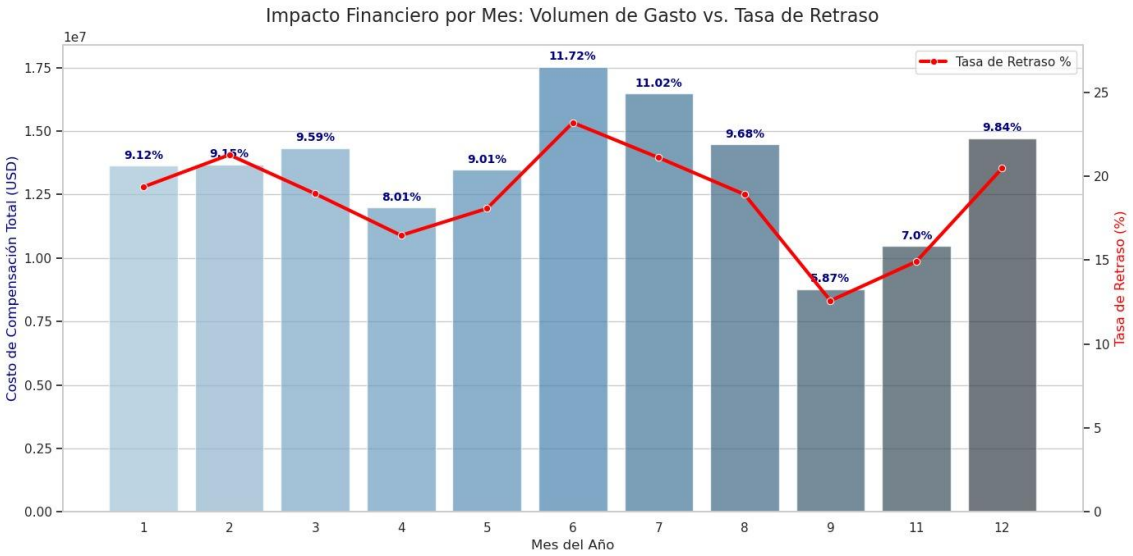

---

3. Metodología y Estrategia de Modelado

Para enfrentar el desbalanceo de datos (predominancia de vuelos a tiempo), se aplicó un **submuestreo**. Esto permitió entrenar al modelo para ser más "agresivo" en la detección de retrasos, priorizando la captura del ahorro financiero sobre la precisión general.

4. Hallazgos Estratégicos del Modelo

Analizando la estructura del modelo, se identificaron tres factores determinantes que activan las alarmas de gasto:

1. **Ventana Crítica:** El modelo marca una frontera clara a las **10:30 AM**. Los vuelos anteriores a esta hora se consideran los activos más seguros.
2. **Hubs de Origen:** Aeropuertos como **Atlanta (ATL) y Denver (DEN)** presentan dinámicas que requieren reglas de decisión específicas para evitar pérdidas masivas.
3. **Bloques de Eficiencia:** El modelo agrupa a las aerolíneas por cumplimiento. Si un operador cae en el grupo de "bajo cumplimiento", se eleva automáticamente la previsión de fondos.

---

5. Comparativa de Desempeño Técnico

Se evaluaron dos arquitecturas: el Árbol de Decisión simple y el Random Forest (Bosque Aleatorio).

Métrica	Árbol de Decisión	Random Forest	Diferencia (Δ)	Ganador
Accuracy	0.5791	0.5842	+0.0051	**Random Forest**
F1-Score	0.6254	0.6300	+0.0046	**Random Forest**
AUC-ROC	0.5890	0.6688	+0.0798	**Random Forest**

- **Validación:** El Random Forest demostró una capacidad de discriminación (AUC-ROC) sustancialmente mayor, siendo el modelo más robusto para capturar la complejidad de la red nacional.

---

6. Impacto Financiero y Resultados Finales

Bajo la implementación del modelo ganador (**Random Forest**), los resultados proyectados son los siguientes:

Ahorro y Eficiencia

Métrica	Árbol de Decisión	Random Forest (Elegido)
Escenario Base (Sin Modelo)	$29,765,700	$29,765,700
Ahorro Efectivo	**$13,426,800**	**$13,635,600**
Eficiencia de Mitigación	45.11%	45.81%
Balance Financiero Neto	**$3,801,300**	**$4,323,300**

Análisis de la "Misión Financiera

		Predicción con el random forest	
		puntual	**retrasado**
real	**puntual**	486,303	381,128
	retrasado	62,082	136,356

1. **Predicciones Correctas (TP):** El modelo detectó **136,356 retrasos**, permitiendo medidas de mitigación oportunas.
2. **Escenarios de Ahorro:** * Escenario solicitado ($150/TP): **$20,453,400 USD**.
    - Escenario realista ($100/TP): **$13,635,600 USD**.

3. **Riesgo Residual (Falsos Negativos):** Se registraron 62,082 casos no detectados, lo que representa un gasto no evitado de **$9,312,300 USD**.

---

7. Conclusiones Ejecutivas

- **Superioridad del Random Forest:** Genera un beneficio adicional de **$522,000 USD** respecto al modelo simple. En una operación de más de 5 millones de registros, este ahorro justifica plenamente el uso de algoritmos complejos y entornos de computación avanzada (PySpark/Docker).
- **Reducción del Riesgo:** La implementación de este sistema permite mitigar casi el **46%** del impacto económico total de los retrasos.
- **Hoja de Ruta:** La mayor oportunidad de optimización financiera reside en la logística de vuelos programados **después de las 10:30 AM** en aeropuertos del grupo de **Atlanta y Denver**, priorizando la gestión de aerolíneas de alto volumen como Southwest, American y Delta.

Síntesis para Finanzas: El modelo actúa como una herramienta de protección de capital, enfocándose no solo donde la tasa de retraso es alta, sino donde las pérdidas son masivas.